

非线性最佳平方拟合

前面介绍的数据拟合最小二乘法属于线性拟合

已知数据点 $\{x_i, f(x_i) = y_i\}_{i=0}^n$

$\varphi_0, \varphi_1, \dots, \varphi_m$ 为线性无关的基函数

取 $P(x) = a_0\varphi_0(x) + \dots + a_m\varphi_m(x)$ 线性叠加

使 $Q(a_0, a_1, \dots, a_m) = \sum_{i=0}^n [P(x_i) - f(x_i)]^2$ 最小

实际问题:

(1) 拟合函数不能表示为参量的线性叠加形式, 如:

$$P(x) = a_0 + a_1 \sin(a_2 x)$$


$$P(x) = a_0 \exp\left[-\frac{1}{2} \left(\frac{x - a_1}{a_2}\right)^2\right] + a_3 + a_4 x + a_5 x^2$$

(2) 拟合函数与参量的关系无法用解析表达式给出, 仅知

$P(x, a_0, a_2, \dots, a_n)$ 可由理论模型数值计算得离散点值。

拟合的目的是找参量 $\{a_k\}_{k=0}^n$ 使计算结果逼近实验结果。

前面的线性拟合方法无法实现!



例如：


测量数据为 $\{x_i, f(x_i), \sigma_i\}_{i=0}^N$

由理论模型方法给出其满足
运动方程：

$$\nabla^2 y(x) + F\{a_1, a_2, \dots, a_M, x, y(x)\} = 0$$

对给定的参量 $\{a_k\}_{k=1}^M$ 可通过数值方法计算得出： $\{x_i, y(x_i)\}$

目的：寻找 $\{a_k^*\}_{k=1}^M$ 使得 $\{y(a_1^* \cdots a_M^*, x_i)\}$ 很好地逼近实验。



非线性最佳平方拟合方法基本原理相同：

实验数据点 $\{x_i, f(x_i) = y_i, \sigma_i\}_{i=0}^N$

找 $P(x), \{a_k\}_{k=1}^n$ 或 $P(x, a_1, a_2, \dots, a_n)$

使 $Q(a_1, a_2, \dots, a_n) = \sum_{i=0}^N \frac{1}{\sigma_i^2} [y_i - P(x_i, a_1, a_2, \dots, a_n)]^2$ 最小

搜索法： $Q(a_1, a_2, \dots, a_n)$ 看成 (a_1, a_2, \dots, a_n) 的连续函数。

在这n维空间，由一组初值 $\{a_k^0\}_{k=1}^n$ 出发

$\{a_k^0\}_{k=1}^n \Rightarrow \{a_k^1\}_{k=1}^n \Rightarrow \dots \Rightarrow \{a_k^*\}_{k=1}^n$ 达到 $Q(a_1^*, a_2^*, \dots, a_n^*)$ 最小

问题： $\{a_k^0\}_{k=1}^n \Rightarrow \{a_k^1 = a_k^0 + \delta a_k^0\}_{k=1}^n$ 如何确定增量 $\{\delta a_k^0\}_{k=1}^n$


1、梯度搜索法(Gradient Search) (最速下降法)

(1) 先看2参数的情况


实验数据点 $\{x_i, f(x_i) = y_i, \sigma_i\}_{i=0}^N$

找 $P(x, a_1, a_2)$ 使 $Q(a_1, a_2) = \sum_{i=0}^N \frac{1}{\sigma_i^2} [y_i - P(x_i, a_1, a_2)]^2$ 最小

$Q(a_1, a_2)$ 为三维空间的曲面, 最低点 $Q^*(a_1^*, a_2^*)$



用一系列平行于 (a_1, a_2) 的平面切割曲面，投影到 (a_1, a_2) 平面，得到一系列等高线，每一曲线 Q 相同，不同的线表不同的 Q ，最小点为 $Q^*(a_1^*, a_2^*)$



(a) 取初始点 (a_1^0, a_2^0) , $Q^0(a_1^0, a_2^0)$ 为相应的等高线

找下一点 $(a_1^1 = a_1^0 + \delta a_1^0, a_2^1 = a_2^0 + \delta a_2^0)$, 使 $Q^1(a_1^1, a_2^1)$

为初始点附近最小

(b) 梯度方向Q上升最快

$$\nabla Q = \frac{\partial Q}{\partial a_1} \hat{a}_1 + \frac{\partial Q}{\partial a_2} \hat{a}_2 \quad \text{梯度沿各参量轴的分量为:}$$

$$\chi_k = \frac{\partial Q}{\partial a_k} / \sqrt{\sum_i \left(\frac{\partial Q}{\partial a_i} \right)^2}$$

取 $\delta a_k = -\Delta a_k \chi_k$, Δa_k 为选定的步长（可自由调节）。

则 $Q^1(a_1^1, a_2^1)$ 为初始点附近Q最小

同样可得: $Q^0(a_1^0, a_2^0) > Q^1(a_1^1, a_2^1) > Q^2(a_1^2, a_2^2) > \cdots > Q^*(a_1^*, a_2^*)$

$$\text{注: } \frac{\partial Q}{\partial a_1} \approx \frac{Q(a_1 + \Delta a_1, a_2) - Q(a_1, a_2)}{\Delta a_1}$$

(2) 多参数的情况

实验数据点 $\{x_i, f(x_i) = y_i, \sigma_i\}_{i=0}^N$

使 $Q(a_1, a_2, \dots, a_n) = \sum_{i=0}^N \frac{1}{\sigma_i^2} [y_i - P(x_i, a_1, a_2, \dots, a_n)]^2$ **最小**

$Q(a_1, a_2, \dots, a_n)$ 为n维空间的曲面，最低点 $Q^*(a_1^*, a_2^*, \dots, a_n^*)$

同样有一系列的等高线，每一曲线 Q 相同，不同的线表不同的 Q ，最小点为 $Q^*(a_1^*, a_2^*, \dots, a_n^*)$

$\nabla Q = \sum_k \left(\frac{\partial Q}{\partial a_k} \hat{a}_k \right)$ 梯度沿各参量轴的分量为：

$$\chi_k = \frac{\partial Q}{\partial a_k} / \sqrt{\sum_i \left(\frac{\partial Q}{\partial a_i} \right)^2}$$

取 $\delta a_k = -\Delta a_k \chi_k$, Δa_k 为选定的步长（可自由调节）。

则 $Q^1(a_1^1, a_2^1, \dots, a_n^1)$ 为初始点附近 **Q** 最小

同样可得：

$$Q^0(a_1^0, a_2^0, \dots, a_n^0) > Q^1(a_1^1, a_2^1, \dots, a_n^1) > \dots > Q^*(a_1^*, a_2^*, \dots, a_n^*)$$

注：
$$\frac{\partial Q}{\partial a_k} \approx \frac{Q(a_1, \dots, a_k + \Delta a_k, \dots, a_n) - Q(a_1, a_2, \dots, a_n)}{\Delta a_k}$$

非线性最佳平方拟合梯度搜索法步骤:

实验数据点 $\{x_i, f(x_i) = y_i, \sigma_i\}_{i=0}^N$

找 $P(x), \{a_k\}_{k=1}^n$ 或 $P(x, a_1, a_2, \dots, a_n)$

(1) 任取参数初值 $\{a_k^0\}_{k=1}^n$ 计算 $Q^0(a_1^0, \dots, a_n^0)$

(2) 取各参数的步长(可自由调节) $\Delta a_k^0, k = 1, \dots, n$

计算梯度沿各参量轴的分量: $\chi_k = \frac{\partial Q}{\partial a_k} / \sqrt{\sum_i \left(\frac{\partial Q}{\partial a_i} \right)^2}$

得 $\delta a_k^0 = -\Delta a_k \chi_k \Rightarrow \{a_k^1 = a_k^0 + \delta a_k^0\}_{k=1}^n \Rightarrow Q^1(a_1^1, a_2^1, \dots, a_n^1)$

(3) 再同样(1)(2)得 $Q^2, \dots, Q^*(a_1^*, a_2^*, \dots, a_n^*)$ 最小

2、网格搜索法(Grid Search)

(略)

3、抛物线外推法(Parabolic Extrapolation)

(略)